Research Revision Notes

Sarcoma_CellMinerCDB পেপারের ব্যাখ্যা এবং প্রথম Research Paper-এর Topic নির্বাচন (Topic C: SLFN11-centered Interpretable Biomarker Model)

উৎস পেপার: Tlemsani C., Heske C.M. et al., *iScience* 2024;27(6):109781, PMCID: PMC11167437 | নোট তৈরি: 6 November 2026

> **এক নজরে পুরো আলোচনা:** (১) একটি resource paper বুঝলাম, (২) তার limitation থেকে research gap বের করলাম, (৩) তিনটি candidate topic দেখলাম, (৪) **Topic C** (সবচেয়ে নিরাপদ) বিস্তারিত বুঝলাম, (৫) একটি staged plan ও ৪ সপ্তাহের roadmap ঠিক করলাম।

১. পেপারটি কী নিয়ে?

Sarcoma (সারকোমা) হলো হাড় (bone) ও নরম টিস্যু (soft tissue) যেমন পেশি, চর্বি, কার্টিলেজের **rare cancer** (বিরল ক্যানসার)।

সমস্যা	ব্যাখ্যা
Rare (বিরল)	রোগী কম, তাই data কম ও ওষুধ কম।
Heterogeneous (বৈচিত্র্যময়)	১৫+ subtype, প্রত্যেকের জীববিজ্ঞান আলাদা।
ফল	কয়েক দশক ধরে বেশির ভাগ subtype-এর patient outcome প্রায় একই।

সমাধান: Sarcoma_CellMinerCDB নামে একটি free web tool। এতে **133টি sarcoma cell line** (ল্যাবে বাড়ানো ক্যানসার কোষের সারি) এর সব তথ্য এক জায়গায় আছে।

উপমা: ১০টি লাইব্রেরিতে ছড়ানো বই এক জায়গায় এনে একটি search engine বানানো।

Data types

Data type	বাংলা অর্থ
Genomic (mutation)	DNA-তে কী কী পরিবর্তন
Transcriptomic (expression)	কোন জিন কতটা সক্রিয় (RNA)
Methylome	DNA-র গায়ে রাসায়নিক "ট্যাগ" (জিনের on/off সুইচ)
Proteomic / Metabolic	প্রোটিন ও বিপাকীয় পদার্থের পরিমাণ
Pharmacologic (drug response)	ওষুধে কোষ কতটা সাড়া দেয়
CRISPR knockout	একটি জিন বন্ধ করলে কোষ বাঁচে কি না
Copy number	একটি জিনের কয়টি কপি আছে
Global Z score	ভিন্ন database-এর expression একই স্কেলে এনে গড় করা (z-score = গড় থেকে কত standard deviation দূরে)

Cell line কী ও কেন?

Cell line = রোগীর টিউমার থেকে নেওয়া কোষ, যা ল্যাবে অনির্দিষ্টকাল বাড়ানো যায়। রোগীর ওপর পরীক্ষার আগে ওষুধ কোষের ওপর পরীক্ষা করা যায়। **সীমাবদ্ধতা:** আসল টিউমারের **microenvironment** (আশপাশের পরিবেশ) নেই, তাই এটি একটি model, আসল রোগী নয়।

Reliability (Reproducibility)

ভিন্ন ল্যাবের data মেলে কি না, তা **Pearson correlation** দিয়ে যাচাই (১ = নিখুঁত মিল):

Data	Median Pearson r
Expression	0.68 – 0.92
Methylation	0.65 – 0.86
Copy number	0.55 – 0.83

অর্থাৎ ডেটা **reproducible** (একই ফল পুনরায় পাওয়া যায়) ও বিশ্বাসযোগ্য। Global Z score ও অন্য source-এর expression-এর মধ্যে correlation আরও বেশি (0.92–0.97)।

২. মূল আবিষ্কারগুলো (Key Findings)

বিষয়	মূল ধারণা
Fusion gene (Ewing sarcoma)	দুটি জিন জুড়ে গিয়ে নতুন "দানব জিন" **EWS-FLI1**, যা রোগের **driver**। FLI1, CD99, SLFN11, NR0B1 বেশি সক্রিয়। CRISPR-এ FLI1 বন্ধ করলে শুধু fusion-positive কোষ মরে, অর্থাৎ **essential gene**।
Rhabdomyosarcoma	**PAX3-FOXO1** fusion থাকলে MYOG, NOS1, OLIG2, PIPOX বেশি সক্রিয় (অন্য sarcoma-তে নয়), তাই **classifier** হতে পারে। NOS1/OLIG2/PIPOX-এর কাজ এখনো অজানা, নতুন গবেষণার সুযোগ।
TMB (Tumor Mutational Burden = প্রতি megabase-এ mutation সংখ্যা)	Ewing-এ সবচেয়ে কম। SK-UT-1 ও SK-UT-1B (leiomyosarcoma)-এ সবচেয়ে বেশি, কারণ **MSH2** (mismatch repair জিন) নষ্ট। MSH2 DNA copy করার ভুল ঠিক করে, নষ্ট হলে ভুল জমে।
STAG2 mutation	Ewing কোষে STAG2 mutation থাকলে **cabozantinib**-এ বেশি সংবেদনশীল। সম্ভাব্য **predictive biomarker**।
ALT (Alternative Lengthening of Telomeres)	**Telomere** = ক্রোমোজোমের মাথার "ঢাকনা"। বেশির ভাগ ক্যানসার **TERT/telomerase** দিয়ে লম্বা রাখে। TERT না থাকলে সম্ভবত ALT পজিটিভ, এবং ATR inhibitor কাজ করতে পারে।
Methylation	**t-SNE** (high-dimensional data-কে 2D ছবিতে আনা) দিয়ে subtype আলাদা হয়। **Outlier:** বহুল ব্যবহৃত Ewing line **A673** অন্যদের সাথে জড়ো হয়নি। Promoter methylation জিন বন্ধ করে (negative correlation), gene body methylation চালু রাখতে সাহায্য করে (positive)। দুটো একসাথে নিলে expression আরও ভালো predict হয়।
ADC (Antibody-Drug Conjugate, "গাইডেড মিসাইল")	Chondrosarcoma-র কিছু line-এ **CD33** বেশি, তাই AML-এর ওষুধ gemtuzumab ozogamicin **repurpose** করার প্রস্তাব। Ewing-এর নতুন surface marker: SLCO5A1, NPY5R, PCDH17, CDH8।

পেপারের "তারকা জিন": SLFN11

> **Intuition:** SLFN11 কোষের "আত্মহত্যার বোতাম"। DNA-তে ক্ষতি হলে SLFN11 বেশি থাকলে কোষ নিজেই মরে যায়। তাই DNA-ক্ষতিকারক ওষুধ (**irinotecan** = TOP1 inhibitor, **talazoparib** = PARP inhibitor) **SLFN11-high** কোষে বেশি কার্যকর। Ewing sarcoma-তে SLFN11 সবচেয়ে বেশি।
>
> **ABCG2** একটি "drug pump", যা ওষুধ কোষের বাইরে ফেলে দেয়। তাই: **High SLFN11 + Low ABCG2 → irinotecan-এ উচ্চ sensitivity**।

৩. Limitations ও Research Gap

Gap	ব্যাখ্যা
১. ছোট sample size	মোট 133 line (Ewing 42, Osteosarcoma 23, Rhabdomyosarcoma 26, বাকি ~42টি ১২টি rare subtype-এ)। Drug analysis-এ 61টি NCI line। Features ২০,০০০+ জিন, samples ~60, এটি **p ≫ n** (high-dimensional, low-sample-size) সমস্যা, সহজেই **overfit** হয়।
২. Predictive model নেই	তারা শুধু একটি জিন বনাম একটি ওষুধ (**univariate**) দেখেছে। কোনো formal ML validation নেই।
৩. Rare subtype-এ data নেই	কোনো subtype-এ ১–২টি line, সেখানে কিছুই শেখা যায় না।
৪. Cell line বনাম রোগী	STAG2 mutation cell line-এ 35%, রোগীতে কম। এটি **distribution shift**।

> **কৌশল:** Gap খোঁজার সবচেয়ে সহজ উপায় হলো পেপারের **Limitations** ও **Discussion** অংশ পড়া।

৪. Paper-এর ধরন বোঝা

	Resource paper (এই পেপার)	ML-method paper (তুমি যা লিখতে পারো)
Contribution	Data সংগ্রহ ও একত্রীকরণ	নতুন/উন্নত model বা পদ্ধতি
প্রমাণ	Reproducibility, known biology মেলানো	Baseline-এর চেয়ে ভালো performance
ঝুঁকি	কম, কিন্তু বিশাল curation পরিশ্রম	Novelty ও rigorous evaluation দরকার

৫. তিনটি Candidate Topic ও Staged Plan

Topic	Intuition	ঝুঁকি
A: Transfer learning দিয়ে sarcoma drug response prediction	হাজারো pan-cancer cell line (GDSC/CCLE) থেকে সাধারণ নিয়ম শেখো (**pre-training**), তারপর sarcoma-তে **fine-tuning**।	মাঝারি
B: Generative AI দিয়ে rare subtype-এর synthetic data	**VAE / cGAN / diffusion** দিয়ে কৃত্রিম expression profile বানিয়ে **data augmentation**।	উচ্চ (৩–৪ নমুনা থেকে generative model শেখা কঠিন, model মুখস্থ করে ফেলে)
C: SLFN11-centered interpretable biomarker model	পেপারের hypothesis LASSO/RF/XGBoost ও SHAP দিয়ে rigorous যাচাই এবং cross-dataset generalization।	কম (সবচেয়ে নিরাপদ)

```
Stage 1 (Core, নিশ্চিত paper):   Topic C  -> baseline models + cross-dataset validation
                |
Stage 2 (Main contribution):     Topic A  -> pan-cancer pre-training -> sarcoma fine-tuning
                |
Stage 3 (Bonus / ablation):      Topic B  -> generative augmentation সাহায্য করে কি না
```

কেন এভাবে? Stage 3 ব্যর্থ হলেও Stage 1+2 হাতে থাকে। "Augmentation কাজ করেনি" সঠিকভাবে দেখানো হলে সেটিও বৈধ **negative result**।

Working title: "*Transfer learning and generative augmentation for drug response prediction in data-scarce sarcoma cell lines*"

৬. Topic C বিস্তারিত

> **এক লাইনে:** Gene expression দেখে আগে থেকে বলা একটি sarcoma cell line irinotecan জাতীয় ওষুধে সাড়া দেবে কি না, model কেন তা বলল তা ব্যাখ্যা করা, এবং দেখা model অন্য ল্যাবের data-তেও কাজ করে কি না।
>
> **Research question:** NCI dataset-এ train করা model কি GDSC/CCLE-তে **generalize** করে?

তিন অংশ: **Prediction** (কে সংবেদনশীল?), **Interpretability** (কোন জিনের কারণে?), **Generalization** (অন্য dataset-এ টেকে কি?)।

৬.১ Data: X ও y

	ব্যাখ্যা	উৎস
y (target)	ওষুধের সাড়া, যেমন irinotecan-এর −log10 IC50	Sarcoma_CellMinerCDB (NCI), GDSC, CCLE/CTRP
X (features)	জিনের expression	একই source
Sample	একটি cell line = একটি সারি (প্রায় 30–78টিsource ভেদে)	

Feature স্তর (সরল থেকে জটিল):

```
Level 1: শুধু SLFN11                        (1 feature)
Level 2: SLFN11 + ABCG2                       (2 features)  <- পেপারের hypothesis
Level 3: কয়েক ডজন জিন (DNA repair, drug transporter, Ewing markers)
Level 4: সব জিন + regularization (LASSO)
```

মূল গল্প: জটিল model কি সরল 2-gene নিয়মের চেয়ে সত্যিই ভালো?

৬.২ Pipeline

```
NCI expression + drug (train)
        |
Preprocessing: normalization, feature selection
        |
Models: Ridge/LASSO -> Random Forest -> XGBoost
        |                          |
   Performance             SHAP (কোন জিন গুরুত্বপূর্ণ?)
        |
Test: GDSC / CCLE (সম্পূর্ণ অদেখা dataset)
        |
তুলনা: Internal CV score বনাম External score
```

৬.৩ তিনটি Model কেন?

Model	Intuition	ভূমিকা
LASSO	রৈখিক সূত্র, কিন্তু **L1 penalty** অপ্রয়োজনীয় জিনের weight শূন্য করে (স্বয়ংক্রিয় feature selection)।	সরল, ব্যাখ্যাযোগ্য baseline
Random Forest	অনেক decision tree-র ভোট, non-linear সম্পর্ক ধরে।	বেশি নমনীয়
XGBoost	একটির ভুল পরের tree ঠিক করে (**boosting**)।	শক্তিশালী, তবে ছোট data-তে overfit-এর ঝুঁকি

ছোট data-তে সরল model প্রায়ই জটিল model-কে হারায়। LASSO জিতলেও সেটি মূল্যবান ফল।

৬.৪ SHAP: Intuition ও Worked Example

Intuition: দলগত প্রকল্পে লাভ হলে প্রত্যেকের অবদান কত? **Shapley value** (game theory) বিভিন্ন ক্রমে সদস্য যোগ করে প্রতিবার লাভ কতটা বাড়ে তার গড় নেয়। **SHAP** একই কাজ করে, সদস্যের জায়গায় feature।

```
Model:  predicted sensitivity = 0.5 + 0.8 x SLFN11 - 0.4 x ABCG2
এক Ewing cell line:  SLFN11 = +2,  ABCG2 = -1  (z-score)

Baseline (গড় prediction)   = 0.5
SLFN11-এর অবদান            = 0.8 x (+2)   = +1.6
ABCG2-এর অবদান             = -0.4 x (-1)  = +0.4
-----------------------------------------------
Prediction                    = 0.5 + 1.6 + 0.4 = 2.5
```

ব্যাখ্যা: cell line অতি সংবেদনশীল (2.5), কারণ SLFN11 বেশি (+1.6) এবং ABCG2 কম (+0.4)। এটি পেপারের hypothesis-এর সাথে মেলে।

> **সতর্কতা:** SHAP বলে **model কী ব্যবহার করছে**, জীববিজ্ঞানে কী **কারণ** তা নয়। লিখবে "SHAP shows SLFN11 is important", কখনো "SLFN11 causes sensitivity" নয়।

৬.৫ আসল প্রশ্ন: Cross-Dataset Generalization

একই dataset-এর ভেতরে cross-validation-এ score সবসময় ভালো আসে (একই ল্যাব, যন্ত্র, পদ্ধতি)। আসল পরীক্ষা হলো অন্য ল্যাবে model কাজ করে কি না।

Model	Internal CV (NCI)	External (GDSC)
SLFN11 only	r = 0.55	r = 0.48
SLFN11 + ABCG2	r = 0.62	r = 0.55
LASSO (সব জিন)	r = 0.70	r = 0.50
XGBoost (সব জিন)	r = 0.78	r = 0.35

এই সংখ্যাগুলো শুধু বোঝার জন্য বানানো উদাহরণ, আসল ফল নয়। এমন ফল এলে বার্তা হবে: XGBoost internal-এ সেরা কিন্তু external-এ সবচেয়ে খারাপ (**overfitting to dataset-specific noise**), আর ছোট data-তে সরল biomarker বেশি নির্ভরযোগ্য।

৬.৬ চারটি বড় ফাঁদ

ফাঁদ	সমাধান
১. Overlapping cell line (একই line NCI ও GDSC দুটোতেই; সবচেয়ে বিপজ্জনক, **data leakage**)	External test থেকে সব overlapping line বাদ দাও।
২. ভিন্ন স্কেল (−log10 IC50, IC50, AUC)	প্রতিটি dataset-এর ভেতরে **z-score** বা **rank transformation**, এবং **Spearman correlation** ব্যবহার।
৩. ভিন্ন expression platform (microarray বনাম RNA-seq)	Per-dataset z-score, বা পেপারের **Global Z score** পদ্ধতি।
৪. ছোট test set (overlap বাদ দিলে ২০–৩০টি line)	**Bootstrap confidence interval** দেখাও (যেমন r = 0.5, 95% CI 0.2–0.7) এবং একাধিক external dataset ব্যবহার করো।

৬.৭ Evaluation split: কেন Leave-One-Subtype-Out?

133 line থেকে random 80/20 split: Train ≈ 106, Test ≈ 27। একই Ewing subtype-এর কাছাকাছি line train ও test দুই জায়গাতেই থাকে, model "Ewing মানেই SLFN11 বেশি" মুখস্থ করে ভালো score পায়, যা সত্যিকারের শেখা নয়।

সঠিক পদ্ধতি: Ewing (42) সম্পূর্ণ test-এ রাখো, বাকি 91টিতে train করো। Score কমবে, কিন্তু এটিই **সৎ মূল্যায়ন**।

৬.৮ Experiment Design (E1–E7)

#	Experiment	প্রশ্ন
E1	Feature level 1–4 তুলনা	জটিলতা কি সত্যিই সাহায্য করে?
E2	Internal CV (stratified, repeated)	NCI-র ভেতরে performance কেমন?
E3	External test (GDSC, CCLE)	Generalize করে কি?
E4	Leave-one-subtype-out	নতুন subtype-এ কেমন?
E5	SHAP stability (বারবার resample)	গুরুত্বপূর্ণ জিনের তালিকা স্থির থাকে কি?
E6	Negative control (label shuffle)	Random-এর চেয়ে সত্যিই ভালো? Score শূন্যের কাছে না হলে pipeline-এ leakage আছে।
E7	অন্য ওষুধ (talazoparib, topotecan)	SLFN11 hypothesis অন্য DNA-damaging ওষুধেও খাটে কি?

৬.৯ সম্ভাব্য ফল ও বার্তা

ফল	Paper-এর বার্তা
সরল 2-gene ≈ জটিল model, দুটোই generalize করে	"Parsimonious biomarker validated across datasets"
জটিল model internal-এ ভালো, external-এ খারাপ	"Complexity hurts in low-sample regimes"
কিছুই generalize করে না	Negative result (rigor থাকলে ছোট venue-এ প্রকাশযোগ্য)
SHAP-এ ABCG2 ছাড়া নতুন জিন বারবার আসে	নতুন hypothesis (সবচেয়ে আকর্ষণীয়)

৬.১০ Honest মূল্যায়ন

শক্তি: Data পাবলিক ও ডাউনলোডযোগ্য; laptop-এই চলবে; leakage ও validation শেখার ভালো প্রশিক্ষণ।

দুর্বলতা: SLFN11 ও irinotecan/PARP inhibitor-এর সম্পর্ক আগেই প্রকাশিত, তাই biology-তে novelty কম। Novelty আসবে **systematic cross-dataset validation + interpretable ML comparison** থেকে। সম্ভাব্য venue: মাঝারি মানের bioinformatics journal, workshop বা conference; top-tier-এর জন্য Stage 2 (transfer learning) লাগবে। এই সুনির্দিষ্ট framing আগে কেউ করেছে কি না তা **এখনো যাচাই হয়নি**, literature check বাকি।

৬.১১ Paper-এর কাঠামো

```
1. Introduction    -> Sarcoma-র সমস্যা, SLFN11 hypothesis, গবেষণা ফাঁক
2. Related Work    -> Drug response prediction (GDSC/CCLE ভিত্তিক), SLFN11 biology
3. Data & Methods  -> Datasets, preprocessing, models, SHAP, evaluation protocol
4. Results         -> E1-E7
5. Discussion      -> ব্যাখ্যা, limitations (cell line != patient)
6. Conclusion      -> মূল বার্তা
```

৭. সাধারণ সতর্কতা ও Roadmap

- **Novelty যাচাই না করে এগিও না।** PubMed/Google Scholar-এ keyword সার্চ করো (যেমন "drug response prediction sarcoma transfer learning", "synthetic gene expression augmentation rare cancer")।
- **Claim ছোট রাখো:** "cell line-এ ভালো predict করে" লেখা যাবে, "রোগীর চিকিৎসায় কাজে লাগবে" লেখা যাবে না।
- **Biology-র একজন সহযোগী** (supervisor/senior) থাকলে ফলের জৈবিক ব্যাখ্যা মজবুত হয়।
- **Reproducibility:** code GitHub-এ, fixed random seed, data version লিখে রাখা।

সপ্তাহ	কাজ
১	Literature review (১৫–২০টি paper): drug response prediction, transfer learning in genomics। Novelty যাচাই।
২	Data download ও cleaning: Sarcoma_CellMinerCDB + GDSC/CCLE। **EDA** (exploratory data analysis)।
৩	Baseline models (LASSO, RF, XGBoost) + সঠিক cross-validation।
৪	প্রথম ফল দেখে Topic A-তে যাওয়ার সিদ্ধান্ত।

আজ থেকেই শুরুর ৩ ধাপ

1. Sarcoma_CellMinerCDB থেকে NCI sarcoma-র **expression + irinotecan data** ডাউনলোড করো।
2. দেখো কয়টি line-এ **দুটোই** আছে (এটিই তোমার আসল n)।
3. SLFN11 বনাম irinotecan-এর scatter plot আঁকো ও Spearman correlation বের করো। পেপারের ফল পুনরুৎপাদন (**reproduce**) করতে পারলে বুঝবে pipeline ঠিক আছে।

> **পরবর্তী সম্ভাব্য কাজ (এখনো বাকি):** (ক) Python skeleton (data loading, normalization, LASSO/RF/XGBoost, SHAP, leave-one-subtype-out), (খ) literature search দিয়ে novelty check।

৮. Glossary (দ্রুত revision)

English keyword	বাংলা অর্থ / সহজ কথা
Cell line	ল্যাবে বাড়ানো ক্যানসার কোষের সারি
Heterogeneous	বৈচিত্র্যময়, নানা ধরনের
Fusion gene	দুটি জিন জুড়ে তৈরি নতুন জিন
Driver	রোগের মূল চালক
Essential gene	বেঁচে থাকার জন্য অপরিহার্য জিন
Biomarker	রোগ বা ওষুধের সাড়ার জৈবিক ইঙ্গিত
Reproducibility	একই ফল পুনরায় পাওয়ার ক্ষমতা
Z score	গড় থেকে কত standard deviation দূরে

p ≫ n	features অনেক বেশি, samples কম
Overfitting	training data মুখস্থ করা, নতুন data-তে ব্যর্থ হওয়া
Data leakage	test-এর তথ্য অজান্তে train-এ ঢুকে পড়া (ফল ফুলে ওঠে)
Generalization	অদেখা data-তে ভালো কাজ করা
Distribution shift	train ও বাস্তব data-র বণ্টন আলাদা হওয়া
Transfer learning	বড় data থেকে শিখে ছোট data-তে কাজে লাগানো
Data augmentation	কৃত্রিমভাবে data বাড়ানো
LASSO / L1 penalty	অপ্রয়োজনীয় feature-এর weight শূন্য করা regularization
Boosting	একটির ভুল পরেরটি ঠিক করে এমন ensemble
SHAP	প্রতিটি feature-এর অবদান মাপার পদ্ধতি (Shapley value ভিত্তিক)
Bootstrap CI	resampling দিয়ে অনিশ্চয়তার সীমা বের করা
Negative control	label এলোমেলো করে pipeline-এর সততা যাচাই
Repurpose	এক রোগের ওষুধ অন্য রোগে ব্যবহার